교육 데이터 기반 학교별 학업중단 예측 모델 구축 : 회귀 트리 모델을 중심으로

최건우
춘천교육대학교 초등교육과
knowball1101@gmail.com

배경 및 목적

학업중단은 개인의 학습 단절을 넘어,
사회 · 경제적 비용 증가와 교육격차 심화 등 다양한 문제를 유발한다.

기존의 연구는 주로 학생의 개인의 **심리 · 정서적 특성,**
가정환경 요인 등에 초점을 맞추었으며 **빅데이터 기반의 예측**
연구는 제한적이었다.

한편, 교육 데이터는 **학교 및 학생 단위로 구조화된 대규모 정보**를 포함하고 있어, 이를 기반으로 다양한 예측 모델을 구축할 수 있는 가능성을 내포하고 있다.

따라서 본 연구는 **회귀 트리 알고리즘을 적용, 고등학교 단위의 학업중단 예측 모델을 구축**하고자 함

본 모델을 통해, **학업중단 위험군을 조기에 탐지**하기 위한 기초로 활용될 것을 기대한다.

연구 방법

1. 데이터 범위 및 대상

본 연구는 **에듀데이터서비스(EDSS)**로부터 제공받은 교육 데이터를 기반으로, **고등학교 단위의 학업중단 예측 모델**을 구축하였다.

해당 데이터는 **모집단의 70%**를 **층화추출**하여 제공되며, 각 항목에 **학교별 고유 식별자(층화학교ID)**가 포함되어 있어. **학교 단위 예측 모델**을 설계할 수 있다.

본 연구에서는 **NEIS**와 **학교정보공시**의 **2023년 고등학교** 데이터를 통합 활용하였다.
- **NEIS**: 학업중단 현황, 학교기본현황 등
- **학교정보공시:** 교직원 구성, 학교 시설, 행정업무 등

데이터는 **층화학교ID**를 기준으로 **Outer Join** 방식으로 병합하였다.
- 병합 과정에서 발생한 **결측값(Null)**은 **0으로 대체**
- **모든 학교에서 동일한 값을 갖는 피처**는 예측력 저하를 방지하기 위해 제거

최종적으로 **120개의 피처**로 구성된 **1차 데이터셋**을 구축하였다.

2. 모델 구축

본 연구에서는 **회귀 트리 모델**인 **의사결정나무(Decision Tree), 랜덤포레스트(Random Forest), XGBoost**를 활용하였다.

트리 계열 모델은 다음의 특징을 가지고 있다.
- 변수 간 **독립성**과 **선형성 가정** 및 **다중공선성** 문제에서 비교적 자유로움
- 따라서 **구조가 복잡한 교육 데이터를 분석하는 데 적합**

예측 모델의 구성은 다음과 같다
- **종속변수**: 학교별 학업중단 학생 수
- **독립변수**: 교육데이터 내 나머지 모든 피처

▶ 의사결정나무
: 각 노드에서 데이터를 분할하여 MSE가 가장 크게 감소하는 split을 선택함

$$\Delta MSE = MSE_{parent} - \left(\frac{n_L}{n} \cdot MSE_L + \frac{n_R}{n} \cdot MSE_R\right)$$

▶ 랜덤포레스트
: 여러 개의 회귀트리를 훈련시켜, 예측값의 평균을 최종 출력으로 사용

$$\hat{y} = \frac{1}{T}\sum_{t=1}^{T} f_t(x)$$

▶ XGBoost
: 잔차를 기반으로 새로운 트리를 반복적으로 추가하여 오차를 보정하는 그래디언트 부스팅

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

3. 모델 최적화 및 피처 분석

본 연구는 모델 성능의 향상과 과적합 방지를 위하여
1차, 2차 최적화 단계를 통해 하이퍼파라미터 튜닝을 수행하였다.

구분	1차 최적화	2차 최적화
대상 모델	의사결정나무, 랜덤포레스트, XGBoost	XGBoost
최적화 방법	Grid Search	Optuna
검증 방식	5-fold 교차 검증, Early Stopping	
평가지표	RMSE(Root Mean Squared Error)	
최종 선정 모델	XGBoost	XGBoost (하이퍼파라미터 재튜닝)

모델 해석
- SHAP(Shapley Additive Explanations)를 통해 분석
- 변수 중요도 정량화, 개별 변수의 예측 기여도 시각화
- 최종 모델의 **해석 가능성 확보**

결과

1. 예측 모델 성능 비교

1차 실험에서 회귀 트리 모델 3가지를 비교한 결과 XGBoost가 가장 높은 예측력을 보임.

Model	RMSE	MAE	R^2
DecisionTree	7.07485695957707	4.91154049278144	0.29564119171732
RandomForest	5.83616674074917	4.08882300194315	0.52069274216618
XGBoost	**5.83008151549795**	**4.04941820108938**	**0.521691744482834**

▶ XGBoost를 최종 분석 모델로 선정

2. 모델 입력 피처의 적절성 검토 및 수정

초기 모델은 **총 120개의 피처**를 기반으로 학업 중단을 예측했으나, 일부 피처는 **학교별 학업중단 현황 통계 발표와 유사한 시점**에서 확인 가능한 데이터로, **사전 예측 목적에 부적합**하다고 판단되어 제거함

▶ 학기 초 수집 가능한 피처로 제한, 총 96개의 피처로 데이터셋을 재구성함.
▶ 제거한 피처는, 학부모상담실적, 위기대상학생수, 상담참여학생수, 위기학업지속학생수, 전문상담시간 등

Model	RMSE	MAE	R^2
1차 XGBoost	5.83008151549795	4.04941820108938	0.521691744482834
2차 XGBoost	**6.18278616706074**	**4.37235260009765**	**0.462068378925323**

▶ 예측에 직접적으로 영향을 줄 것으로 예상되는 피처를 제거하였음에도 불구, 준수한 모델 성능을 유지함

3. 최적 피처 수 탐색

최적 피처 수 탐색을 위해 SHAP 분석을 통해
변수 중요도를 도출, 상위 피처부터 순차적으로 누적 적용
성능이 가장 우수한 피처 개수 탐색

▶ 1차 실험으로 피처 수 20~100 사이에서 10개씩 누적하며 분석
▶ RMSE 감소량에 비해 $Adjusted\ R^2$의 감소가 급격하게 발생, $Adjusted\ R^2$이 가장 높은 피처 수 30으로 1차 선정
▶ 피처 수 30부근에서 실험한 결과 **피처 수 33개** 일 때 최적 성능

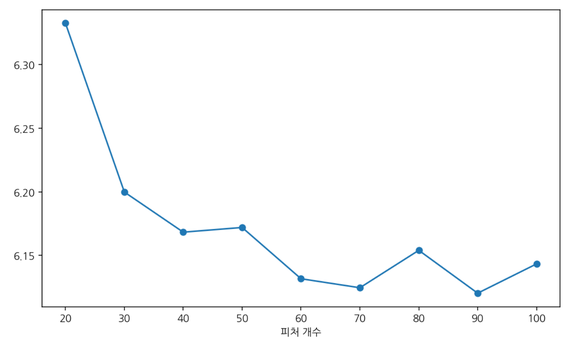

[그림1] 피처 수(20~100)에 따른 RMSE의 변화

Features	RMSE	$Adjusted\ R^2$
30	6.199781463	0.424059854
31	6.247225031	0.413945612
32	6.190923495	0.423212947
33	**6.150992535**	**0.429391637**
34	6.284726524	0.403011938
35	6.194958132	0.418677911

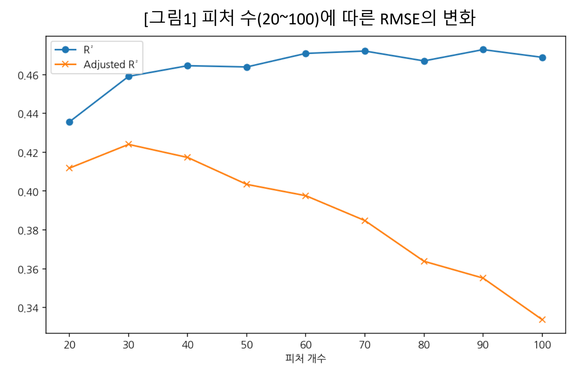

[그림2] 피처 수(20~100)에 따른 R^2 , $Adjusted\ R^2$의 변화

4. 최종 모델 구축

피처 수 33을 기준으로 최종 XGBoost 모델 **($Adjusted\ R^2$ ≒ 0.429)**을 구축하였다.

Model	RMSE	MAE	R^2	$Adjusted\ R^2$
XGBoost (Features=33)	**6.150992535**	**4.315666676**	**0.467586517**	**0.429391637**

5. SHAP 분석

▶ SHAP 분석을 통해 각 피처 별 예측 기여도를 정량적으로 분석
▶ 분석 결과 학급수, 학과수, 교원수, 일교실수 등의 순으로 학교 별 학업중단 학생 수 예측의 주요 피처로 확인됨
▶ 시각화 결과 상위 20개의 피처 중에서 기숙사수, 교과교실수, 도서관 대여 학생수, 월별학교기본_학생수 피처는 X축의 양의 방향으로 파란 점이 몰려있음. 이는 해당 피처들이 학교별 학업중단 학생수 예측과 **음의 상관관계**가 있음을 시사함

Feature	Importance
월별학교기본_학급수	1.6375314
학과수	1.4685516
교원수	0.8295478
일반교실수	0.6647996
월별학교기본_여학생수	0.47662053
기숙사수	0.39675596
여자기간제교원수	0.33141097
교과교실수	0.26077566
도서관대여학생수	0.23187205
월별학교기본_학생수	0.219629

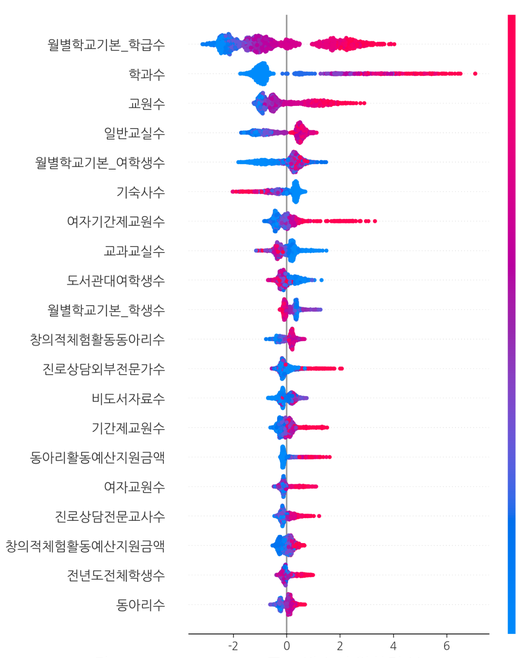

[그림3] SHAP Summary Plot: 주요 변수의 영향력 분포

결론

본 연구는 학기 초 수집 가능한 교육 데이터를 바탕으로 고등학교 단위의 학업중단 예측 모델을 제시하였다. **최적 피처 수(33개)** 기반의 XGBoost 모델은 **$Adjusted\ R^2$ ≒ 0.429** 의 예측 성능을 나타냈으며, SHAP 분석을 통해 학급 수, 학과 수, 교원 수 등 주요 요인을 도출하였다. 이는 향후 학업중단 위험군의 조기 파악과 정책 자원 배분의 근거자료로 활용될 수 있다.